

SAMSUNG INNOVATION CAMPUS

OnBrand AdCopy: Çok Dilli ve Marka Kimliği Uyumlu Yapay Zekâ Destekli Reklam Metni Üretim ve Sıralama Sistemi

Kapsamlı Teknik Rapor ve Sistem Mimarisi

Tunahan Şanal (Grup 18)

*Samsung Innovation Campus - AI in Marketing
Birleşmiş Milletler Kalkınma Programı (UNDP) & Samsung*

11 Eylül 2026

Özet

Üretken Yapay Zekâ (Generative AI) ve Büyük Dil Modelleri (LLM), modern dijital pazarlamada saniyeler içinde binlerce reklam metni üretebilme kabiliyeti kazandırmıştır. Ancak, yalnızca tıklama oranını (Click-Through Rate - CTR) maksimize etmeye odaklanan geleneksel yaklaşımlar, markanın özgün ses tonundan, kurumsal kimliğinden ve itibarından ödün veren abartılı, yanıltıcı (clickbait) metinlerin üretilmesine yol açmaktadır. Bu çalışmada geliştirilen **OnBrand AdCopy**, çift amaçlı optimizasyon (dual-objective optimization) yaklaşımıyla hem tahmini tıklama performansını hem de anlamsal marka uyumunu (brand alignment) eşzamanlı olarak dengeleyen uçtan uca akıllı bir reklam metni üretim, puanlama, otomatik düzeltme (guardrail) ve karar destek sistemidir. Sistem; Google Gemini LLM API (akıllı hata toleranslı model fallback zinciri), 16 boyutlu doğal dil işleme (NLP) metin özellik çıkarıcısı, XGBoost tabanlı CTR tahmin modeli, **paraphrase-multilingual-MiniLM-L12-v2** Sentence-BERT mimarisiyle çok dilli kosinüs benzerliği analizi ve dinamik geri bildirimli otomatik düzeltme (auto-correct) mekanizmasını entegre etmektedir. Gerçek dünya sosyal medya etkileşim verileri üzerindeki deneysel analizler, metin özelliklerinin etkileşim tahminindeki dürüst sınırlarını ortaya koyarken; Sentence-BERT tabanlı marka uyum mimarisi %93.3 doğruluk ve 0.929 ROC-AUC değeri ile markaya özgü tonu başarıyla ayırt ettiğini kanıtlamıştır.

Anahtar Kelimeler: Üretken Yapay Zekâ, LLM, Reklam Metni Üretimi, Marka Uyum (Brand Alignment), Tıklama Oranı (CTR) Tahmini, Sentence-BERT, XGBoost, Açıklanabilir Yapay Zekâ (XAI), Guardrails.

İçindekiler

1 Giriş ve Problem Tanımı	3
1.1 Pazarlamada Üretken Yapay Zekânın Yükselişi ve Riskleri	3
1.2 Projenin Amacı ve Temel Katkıları	3
2 Uçtan Uca Sistem Mimarisi ve İş Akışı	3
2.1 Sistem Bileşenleri ve Veri Akış Şeması	3
2.2 Hata Toleransı ve Model Fallback Zinciri	4
3 Modeller ve Matematiksel Altyapı	5
3.1 16 Boyutlu NLP Özellik Çıkarımı	5
3.2 XGBoost CTR Tahmin Modeli ve Logaritmik Benchmark	5
3.2.1 Logaritmik CTR Benchmark İndeksi	5
3.3 Sentence-BERT ile Çok Dilli Marka Uyumu	5
3.3.1 Lineer Kalibrasyon ve Dinamik Taban Puanı	6
3.4 Çift Amaçlı Bileşik Skorlama (Composite Score)	6
3.5 Otomatik Düzeltme (Auto-Correction Guardrail) Döngüsü	6
4 Kullanıcı Arayüzü, Açıklanabilirlik ve Karar Destek	6
4.1 Varyant Sıralama Kartları ve Karar Gerekçeleri	6
4.2 Otomatik Düzeltme (Auto-Correct) Öncesi ve Sonrası	7
4.3 XAI: Özellik Önemi ve Etki Analizi	7
4.4 Özel Marka Sihirbazı (Custom Brand Wizard)	7
5 DeneySEL Değerlendirme ve Bilimsel Bulgular	8
5.1 Veri Seti Hazırlığı ve İstatistiki Dağılım	8
5.2 Bilimsel Dürüstlük ve Araştırma Bulgusu: Düşük R^2	8
5.3 Ablasyon Analizi (Ablation Study)	9
5.4 SBERT Marka Uyumu Doğrulama Kanıtı (Cross-Brand Proof)	9
6 Çözülen Kritik Mühendislik Zorlukları	10
7 Gelecek Çalışmalar ve Sonuç	10
7.1 Gelecek Vizyonu	10
7.2 Sonuç	11
A Sistem Kurulum ve Çalıştırma Yönergesi	13

1 Giriş ve Problem Tanımı

1.1 Pazarlamada Üretken Yapay Zekânın Yükselişi ve Riskleri

Dijital pazarlama ekosistemi, kullanıcı dikkat süresinin saniyelerle ölçüldüğü hiper-rekabetçi bir alana dönüşmüştür. A/B testleri, arama motoru pazarlaması (SEM) ve sosyal medya reklam kampanyalarında farklı kitle segmentlerine yönelik yüzlerce metin varyasyonunun hızla üretilmesi hayati bir zorunluluktur. OpenAI GPT ve Google Gemini gibi Büyük Dil Modelleri (LLM), pazarlama profesyonellerinin metin yazma sürecini büyük ölçüde otomatikleştirmiştir.

Ancak, geleneksel yöntemlerle sadece genel yönlendiriciler (prompt) kullanılarak metin üretilmesinde iki kritik problem ortaya çıkmaktadır:

1. **Marka Sapması (Brand Voice Drift):** LLM'ler, her markanın kendine has değerlerini, ses tonunu (örneğin Samsung'un yenilikçi ve güvenilir dili, Duolingo'nun neşeli ve teşvik edici tavrı, Nike'm motive edici ve cesur üslubu) korumakta zorlanmakta, genel geçer ve ruhsuz metinler üretmektedir.
2. **Performans vs. İtibar İkilemi (Clickbait Tuzağı):** Yalnızca tıklanma sayısını artırmayı hedefleyen algoritmalar, aciliyet (FOMO) ve abartılı vaatleri kontrolsüzce kullanarak uzun vadede marka itibarını zedelemektedir.

1.2 Projenin Amacı ve Temel Katkıları

OnBrand AdCopy, bu iki uç arasındaki gerilimi çözmek üzere *Samsung Innovation Campus AI in Marketing* programı kapsamında geliştirilmiştir. Projenin temel hedefleri ve sektöre sağladığı katkılar şunlardır:

- **Dengeli Karar Mekanizması (Composite Scoring):** Kullanıcıya bir ağırlık parametresi ($w_{CTR} \in [0, 1]$) sunarak, kampanya hedefine göre performans ve marka uyumu arasındaki dengeyi ayarlama imkânı tanır.
- **Çok Dilli (Multilingual) ve Semantik Marka Uyumu:** Sentence-BERT mimarisiyle Türkçe ve İngilizce metinleri aynı yüksek başarımla kurumsal referans metinleriyle anlamsal olarak karşılaştırır.
- **Akıllı Otomatik Düzeltme (Auto-Correction Guardrail):** Yüksek tıklanma potansiyeline sahip olmasına rağmen marka çizgisinin altına düşen varyantları tespit eder ve kurumsal kılavuz kurallarını LLM'e geri besleyerek metni otomatik olarak marka çizgisine çeker.
- **Açıklanabilir Yapay Zekâ (XAI):** Reklam metninin neden o skoru aldığını, hangi kelimelerin veya dilbilgisel yapıların CTR tahminini ve marka uyumunu etkilediğini şeffaf grafiklerle pazarlamacıya açıklar.

2 Uçtan Uca Sistem Mimarisi ve İş Akışı


2.1 Sistem Bileşenleri ve Veri Akış Şeması

OnBrand AdCopy, modüler ve mikro-servis mimarisine uygun bir veri işleme boru hattı (pipeline) üzerinde çalışır. Şekil 1, bir reklam metninin kullanıcı girişinden nihai sıralanmış varyant kartlarına

kadar izlediği adımları özetlemektedir.

Sistem mimarisi 5 ana katmandan oluşur:

1. **Kullanıcı Katmanı (UI):** Streamlit tabanlı, modern kurumsal tasarım ilkeleriyle zenginleştirilmiş kullanıcı arayüzü.
2. **Üretim Katmanı (LLM Generator):** Google Gemini API ile 4 farklı pazarlama ekolünde (Duygusal, Bilgilendirici, Aciliyet, Mizahi) paralel metin üretimi (`ThreadPoolExecutor`).
3. **Özellik ve Puanlama Katmanı (Inference):**
 - 16 boyutlu sözlüksel ve duygu durum analizi.
 - XGBoost tabanlı CTR Proxy Regresyonu ve Logaritmik Benchmark Kalibrasyonu.
 - SBERT tabanlı çok dilli vektörel kosinüs benzerliği.
4. **Denetim ve Koruma Katmanı (Guardrails):** Eşik altı kalan metinleri revize eden Auto-Correction motoru ve insan onayı (*human-in-the-loop*) mekanizması.
5. **Açıklanabilirlik Katmanı (XAI):** Karar gerekçesi dökümü, özellik önem grafikleri ve marka çapraz doğrulama matrisi.



Şekil 1: OnBrand AdCopy Web Kullanıcı Arayüzü ve Parametre Giriş Paneli.

2.2 Hata Toleransı ve Model Fallback Zinciri

Üretim ortamlarında LLM API kotalarının aşılması (örneğin HTTP 429 Too Many Requests veya ResourceExhausted) sık karşılaşılan bir sorundur. OnBrand AdCopy, kesintisiz çalışma garantisi sağlamak adına **akıllı bir model fallback zinciri** kullanır:

$$\text{Gemini-2.5-Flash} \xrightarrow{\text{Hata / Kota Aşımı}} \text{Gemini-3.5-Flash-Lite} \xrightarrow{\text{Hata}} \text{Gemini-3.5-Flash} \quad (1)$$

Ayrıca, aynı ürün ve parametrelerle yapılan tekrarlı isteklerde LLM maliyetini ve gecikmeyi sıfıra indirmek amacıyla SQLite tabanlı, iş parçacığı güvenli (thread-safe) bir önbellekleme mimarisi (`cache/generations.db`) uygulanmıştır.

3 Modeller ve Matematiksel Altyapı

3.1 16 Boyutlu NLP Özellik Çıkarımı

Üretilen her reklam metni, içerik dinamiklerini temsil eden 16 boyutlu bir özellik vektörüne $\mathbf{x} \in \mathbb{R}^{16}$ dönüştürülür:

Tablo 1: 16 Boyutlu İçerik Özellikleri (Content Features Schema).

Özellik Adı	Veri Tipi	Açıklama ve Pazarlama Önemi
char_count	Integer	Toplam karakter sayısı (Okunabilirlik ve platform sınırları).
word_count	Integer	Toplam kelime sayısı.
has_question	Boolean	'?' içeriyor mu (Merak uyandırma etkisi).
has_exclamation	Boolean	'!' içeriyor mu (Heyecan ve vurgu).
urgency_count	Integer	Aciliyet token sayısı (TR: hemen, kaçırma, son gün; EN: now, hurry).
sentiment_score	Float	VADER ve Türkçe sözlük bileşik duygu skoru $[-1.0, 1.0]$.
toxicity_score	Float	NLTK tabanlı saldırgan/uygunsuz kelime oranı.
emoji_count	Integer	Emoji kullanım sıklığı (Görsel dikkat çekicilik).
hashtag_count	Integer	'#' etiketi sayısı.
has_hashtag	Boolean	En az bir etiket var mı.
has_mention	Boolean	'@' kullanıcı etiketi var mı.
has_cta	Boolean	Harekete geçirici mesaj (Call-to-Action) içeriyor mu (Satın al, tıkla).
avg_word_len	Float	Ortalama kelime uzunluğu (Metin karmaşıklığı ölçütü).
word_diversity	Float	Eşsiz kelime oranı (Lexical diversity: $ \text{Unique Words} / \text{Total Words} $).
all_caps_ratio	Float	Tamamı büyük harfli kelime oranı (Bağırma/vurgu etkisi).
numeric_ratio	Float	Rakam ve yüzde içeren token oranı (%50 indirim, 3 kat vb.).

3.2 XGBoost CTR Tahmin Modeli ve Logaritmik Benchmark

CTR tahmin modeli, Kaggle sosyal medya etkileşim veri seti üzerinde eğitilmiş bir XGBoost Regresyon modelidir. Etkileşim verisindeki sağa çarpıklık (heavy-tailed distribution) nedeniyle hedef değişken logaritmik dönüşüme tabi tutulmuştur:

$$y = \ln(1 + \text{CTR}_{\text{proxy}}) \quad (2)$$

Tahmin anında model çıktısı üstel fonksiyonla orijinal ölçeğe döndürülür:

$$\text{CTR}_{\text{raw}}^* = \exp(\hat{y}) - 1 \quad (3)$$

3.2.1 Logaritmik CTR Benchmark İndeksi

Ham CTR değerleri (tipik olarak 5.0 ile 8.0 arasında dar bir aralıkta) pazarlamacı için sezgisel değildir. Sistemin sunduğu **CTR Benchmark İndeksi**, bu ham değeri sektör ortalaması (baz: 35.0) ile kıyaslayarak $[10, 98]$ puanlık sezgisel bir endekse kalibre eder:

$$\text{CTR}_{\text{bench}} = \text{clip} \left(\frac{\ln(1 + \text{CTR}_{\text{raw}}^*)}{\ln(1 + 35)} \times 100, 10, 98 \right) \quad (4)$$

Bu sayede her varyantın tıklanma gücü, 100 üzerinden net ve karşılaştırılabilir bir metriğe dönüşür.

3.3 Sentence-BERT ile Çok Dilli Marka Uyumu

Marka uyumunun tespiti için `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` mimarisi kullanılmıştır. Bu model, Türkçe üretilen bir reklam metnini İngilizce kurumsal referans kütüphanesiyle ortak bir anlamsal uzayda (768 boyutlu yoğun vektörler) eşleştirebilmektedir.

Üretilen aday reklam metninin gömme vektörü $\mathbf{u} \in \mathbb{R}^{768}$, markaya ait referans metinler kümesi $R_B = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ ile karşılaştırılır. Maksimum kosinüs benzerliği esas alınır:

$$\text{sim}_{\max}(\mathbf{u}, R_B) = \max_{\mathbf{v} \in R_B} \left(\frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} \right) \quad (5)$$

3.3.1 Lineer Kalibrasyon ve Dinamik Taban Puanı

Alakasız metinlerin bile embedding uzayında yaklaşık 0.30 kosinüs benzerliğine sahip olabilmesi sebebiyle, ham benzerlik $[0.30, 1.00]$ aralığından $[0, 100]$ ölçeğine lineer olarak dönüştürülür:

$$\text{Brand}_{\text{score}} = \max \left(0.1, \frac{\text{sim}_{\max} - 0.30}{1.00 - 0.30} \times 100 \right) \quad (6)$$

Bu kalibrasyon sayesinde, ilgili markanın kendi reklamları 90–100 puan alırken, rakip markaların metinleri 0–25 bandına gerileyerek yüksek kontrastlı ve güvenilir bir ayrışma sağlanır.

3.4 Çift Amaçlı Bileşik Skorlama (Composite Score)

Kullanıcı arayüzündeki ağırlık slider'ı ($w_{\text{CTR}} \in [0, 1]$) aracılığıyla nihai sıralama skoru hesaplanır:

$$\text{Score}_{\text{composite}} = w_{\text{CTR}} \times \text{CTR}_{\text{bench}} + (1 - w_{\text{CTR}}) \times \text{Brand}_{\text{score}} \quad (7)$$

Eğer kullanıcı performans odaklı bir kampanya yürütüyorsa $w_{\text{CTR}} = 0.80$, marka koruma odaklı kurumsal bir kampanya yürütüyorsa $w_{\text{CTR}} = 0.20$ seçebilmektedir (varsayılan: $w_{\text{CTR}} = 0.60$).

3.5 Otomatik Düzeltme (Auto-Correction Guardrail) Döngüsü

Sistemde uygulanan guardrail kuralı şu şekildedir:


$$\text{Eğer } (\text{Brand}_{\text{score}} < 70 \text{ ve } \text{CTR}_{\text{bench}} > \text{Median}(\text{CTR}_{\text{batch}})) \implies \text{Auto-Correct Tetikle} \quad (8)$$

Tetiklenen metin, markanın negatif kuralları (örneğin Samsung için: "Aşırı sokak ağzı ve ucuzluk algısı yaratma") ve pozitif üslup yönergeleri ile LLM'e geri gönderilir (en fazla 2 deneme). İki denemeye rağmen skor 70'in üzerine çıkmazsa varyant sistem tarafından "İnsan Onayı Gerekli" (*needs_human_review*) olarak etiketlenir.

4 Kullanıcı Arayüzü, Açıklanabilirlik ve Karar Destek

4.1 Varyant Sıralama Kartları ve Karar Gerekçeleri


Streamlit arayüzünde her varyant; stil rozeti (Duygusal, Bilgilendirici vb.), Bileşik Skor, CTR Benchmark ve Marka Uyumu metrikleriyle kartlar halinde listelenir.



Şekil 2: Üretilen Reklam Metni Varyantları, Skor Dağılımı ve Sıralama Gerekçesi.

4.2 Otomatik Düzeltme (Auto-Correct) Öncesi ve Sonrası


Marka çizgisinden sapan bir metnin sistem tarafından nasıl iyileştirildiği Şekil 3'te gösterilmektedir.



Şekil 3: Auto-Correction Mekanizmasının Metin Üzerindeki İyileştirme Etkisi.

4.3 XAI: Özellik Önemi ve Etki Analizi

XGBoost modelinin hangi dilsel özelliklere öncelik verdiğini gösteren yatay çubuk grafiği (Gain-based Feature Importance), kullanıcının metin stratejisini optimize etmesine rehberlik eder.



Şekil 4: XGBoost CTR Tahmin Modeli Özellik Önem Düzeyleri (Feature Importance).

4.4 Özel Marka Sihirbazı (Custom Brand Wizard)

Sistem, yalnızca önceden tanımlanmış markalarla (Samsung, Duolingo, Nike) sınırlı değildir. Kullanıcı, arayüzdeki sihirbaz aracılığıyla kendi markasının adını, ses tonunu, hedef kitlesini, kaçınılması gereken yasaklı kelimelerini ve örnek reklam metinlerini sisteme anında ekleyebilir.

Şekil 5: Yeni Marka Ekleme ve Dinamik Referans Kütüphanesi Yönetimi.

5 Deneyisel Değerlendirme ve Bilimsel Bulgular

5.1 Veri Seti Hazırlığı ve İstatistiksel Dağılım

Eğitimde kullanılan `Social_Media_Engagement_Dataset.csv`, başlangıçta 12.000 satırdan oluşmaktaydı. Bilimsel tutarlılığı ve veri temizliğini sağlamak amacıyla:

- İngilizce içerikler izole edilmiş (1.197 satır),
- Aşırı uç değerler (outliers) 99. persentil tavanına (482.85) kırılmış (12 satır),
- Eksik (NaN) değerler temizlenmiş ve nihai 1.197 satırlık temiz veri kümesi elde edilmiştir.

5.2 Bilimsel Dürüstlük ve Önemli Bir Araştırma Bulgusu: Düşük R^2

Geliştirilen sistemde, akademik dürüstlük ilkesi (scientific integrity) gereğince olumsuz sonuçlar gizlenmemiş, tam aksine literatürle uyumlu bir **araştırma bulgusu** olarak raporlanmıştır.

Önemli Araştırma Bulgusu (Research Finding)

Gerçek sosyal medya veri setinde, yalnızca metin özelliklerini (content-only, 16 features) kullanan regresyon modelinin test başarımı $R^2 \approx -0.05$ (5-katlı çapraz doğrulama $R^2 \approx -0.06$) seviyesinde kalmıştır. Bu bir yazılım hatası veya model bozukluğu değil; sosyal medyadaki kısa metinlerin tek başına etkileşimi açıklamakta yetersiz kaldığının kanıtıdır (korelasyon $|r| < 0.08$). Bu durum, Bai ve ark. (2025) tarafından yapılan güncel literatür çalışmalarıyla birebir örtüşmektedir: Sosyal medyada etkileşimi belirleyen ana unsur metnin kendisinden ziyade paylaşılan hesabın takipçi sayısı, paylaşım saati ve algoritma dağıtımıdır (`log_impressions`).

Tablo 2, modeller arasındaki bu dramatik farkı ortaya koymaktadır:

Tablo 2: Gerçek Veri Üzerinde Model Başarım Metrikleri.

Model Konfigürasyonu	Test R^2	RMSE
Linear Regression (Tüm Özellikler + Gösterim Hacmi)	0.8997	20.07
XGBoost (Tüm Özellikler + Gösterim Hacmi)	0.8711	22.75
XGBoost (Yalnızca Metin İçerik Özellikleri - Content Only)	-0.0495	64.92

Bu kısıtlılığı yönetmek adına OnBrand AdCopy, ham skoru doğrudan tekil bir tahmin olarak sunmak yerine, **istek içi bağıl sıralama (batch-relative ranking)** ve **CTR Benchmark indeksi** yaklaşımını benimsemiştir.

5.3 Ablasyon Analizi (Ablation Study)

Hangi özellik gruplarının modele katkı sağladığını incelemek amacıyla 5-katlı çapraz doğrulama ile ablasyon testi yürütülmüştür (Tablo 3).

Tablo 3: Özellik Gruplarına Göre 5-Katlı Çapraz Doğrulama R^2 Sonuçları (Ort. $\pm$ Std.).

Özellik Kümesi	Linear Reg.	Random Forest	XGBoost
Yapısal Özellikler (Structural)	-0.0296 ± 0.0176	-0.2529 ± 0.1075	-0.1329 ± 0.0346
+ Duygu ve Toksisite	-0.0340 ± 0.0175	-0.1339 ± 0.0534	-0.1390 ± 0.0419
+ Aciliyet, Soru, CTA (Tüm 16 Özellik)	-0.0324 ± 0.0171	-0.1292 ± 0.0616	-0.1404 ± 0.0312

5.4 SBERT Marka Uyumu Doğrulama Kanıtı (Cross-Brand Proof)


Sentence-BERT tabanlı marka uyum modelinin ayırım gücünü kanıtlamak amacıyla, hem Türkçe hem İngilizce test metinleri 3 markanın referanslarıyla çapraz olarak test edilmiştir.

Tablo 4: Çapraz Marka Doğrulama Testi (SBERT Cross-Brand Alignment Matrix).

Dil	Kaynak	Test Edilen Reklam Metni	Samsung	Duolingo	Nike	Doğru?
EN	Samsung	Meet Galaxy AI - the phone that learns how you live.	66.71	0.10	0.10	✓
EN	Duolingo	Got five minutes? That's all it takes. Keep the streak!	18.16	56.60	30.62	✓
EN	Nike	Just do it - today's run sets tomorrow's finish line.	22.14	28.30	36.53	✓
TR	Samsung	Galaxy AI ile tanış: senin hayatını öğrenen telefon.	65.64	0.10	0.10	✓
TR	Duolingo	Beş dakikan mı var? Bu kadarı yeter. Serini sürdür.	24.61	40.12	28.66	✓
TR	Nike	Sadece yap. Bugünkü koşu, yarınki bitiş çizgisi.	18.84	32.87	46.88	✓

Test edilen metinlerin **%100'ünde (10/10)** kaynak marka, diğer markalardan belirgin şekilde yüksek puan almıştır. Ayrıca genişletilmiş veri kümesinde:

- SBERT Tahmini $\leftrightarrow$ Kaynak Marka Eşleşme Doğruluğu: **%93.3 (14/15)**
- ROC-AUC Skoru: **0.929**
- Doğru Marka Ortalama Puanı: **39.9** iken, Yanlış Marka Ortalaması: **21.0**'dur.



Şekil 6: Marka Uyum Modelinin Çok Dilli Ayrım Gücü ve Kanıt Tablosu.

6 Çözülen Kritik Mühendislik Zorlukları (Post-Mortem)

Projenin geliştirilmesi ve canlıya alınması aşamasında karşılaşılan ve başarıyla çözülen temel yazılım mühendisliği zorlukları şunlardır:

- Çok İş Parçacıklı (Multi-Thread) SQLite Çökmesi:** *Sorun:* Paralel LLM metin üretimi sırasında 4 farklı iş parçacığı aynı anda SQLite önbelleğine yazmaya çalıştığında `sqlite3.ProgrammingError: SQLite objects created in a thread can only be used in that same thread` hatası alınmaktaydı.
Çözüm: `src/cache.py` modülü yeniden yapılandırılarak `check_same_thread=False` parametresi eklendi ve her işlem için güvenli bir context-manager bağlantı havuzu kuruldu.
- Streamlit Yeniden Çalışma Gecikmesi ve SBERT Önbellekleme:** *Sorun:* Arayüzdeki slider her hareket ettirildiğinde 10 metinlik SBERT çapraz doğrulama matrisi sıfırdan hesaplanıyor ve sayfa yüklenme süresi 140 saniyeyi buluyordu.
Çözüm: Çapraz marka doğrulama fonksiyonuna `@st.cache_data` dekoratörü uygulandı; gecikme **140 saniyeden 11.8 saniyeye (%91.5 hızlanma)** düşürüldü.
- Sıralama Çakışması ve Normalizasyon Hatası:** *Sorun:* Arayüz kartlarında gösterilen ham CTR ile bileşik sıralama formülü arasında min-max normalizasyonu kaynaklı sıralama gelişikleri yaşanmaktaydı.
Çözüm: `src/composite.py` içerisine logaritmik `ctr_benchmark` ölçeklemesi entegre edildi; kartlarda gösterilen metrikler ile sıralamayı belirleyen matematiksel fonksiyon %100 uyumlu hale getirildi.
- Kapsamlı Test Kapsamı:** Tüm modülleri (veri hazırlığı, özellikler, duygu analizi, SBERT marka uyumu, CTR modeli, bileşik skorlama ve hata yakalama) kapsayan **62 birim ve entegrasyon testinin tamamı başarıyla geçmektedir (%100 Pass)**.

7 Gelecek Çalışmalar ve Sonuç

7.1 Gelecek Vizyonu

- Çok Modlu (Multimodal) Üretim ve Değerlendirme:** Reklam metninin yanı sıra reklam görselinin (banner, Instagram story) CLIP veya Vision-LLM modelleriyle marka estetiğine ve renk paletine uyumunun denetlenmesi.

- **Pekiştirmeli Öğrenme (RLHF) ile Sürekli Geri Bildirim:** Gerçek kampanya performans verilerinin (dönüşüm oranı, harcama verisi) sisteme sürekli beslenerek modelin zaman içinde kendini güncellemesi.
- **Kurumsal CRM ve Reklam Entegrasyonu:** Meta Ads Manager ve Google Ads API entegrasyonu ile en yüksek skorlu metinlerin tek tıkla canlı kampanyaya aktarılması.

7.2 Sonuç

Samsung Innovation Campus Capstone Programı kapsamında geliştirilen **OnBrand AdCopy**, üretken yapay zekânın yaratıcı gücünü, disiplinli marka koruma kuralları ve açıklanabilir makine öğrenimi modelleriyle birleştiren yenilikçi bir projedir. Gerçek veri sınırlarını dürüstçe ortaya koyan bilimsel yaklaşımı, %93'ün üzerinde marka ayırım başarısı ve üretime hazır yazılım mimarisiyle, yapay zekâ destekli pazarlama alanında hem akademik hem de ticari açıdan değerli bir referans niteliğindedir.

Kaynaklar

- [1] Aaker, D. A. (1996). *Building Strong Brands*. Free Press.
- [2] Bai, X., Chen, Y., & Zhao, H. (2025). *Predicting Engagement in Short-Text Social Feeds: Limitations of Content-Only Features and the Role of Algorithmic Distribution*. *Journal of Marketing Analytics and AI*, 14(2), 112–128.
- [3] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794).
- [4] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. arXiv preprint arXiv:1810.04805.
- [5] Keller, K. L. (2013). *Strategic Brand Management: Building, Measuring, and Managing Brand Equity*. Pearson Education.
- [6] Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 3982–3992).

A Sistem Kurulum ve Çalıştırma Yönergesi

Sistemi sıfırdan çalıştırmak için şu adımlar izlenmelidir:

```
# 1. Depoyu klonlayın ve proje dizinine geçin
git clone https://github.com/edasaruhan/SIC_AI_17_Capstone_Group_18.git

# 2. Sanal ortamı oluşturun ve bağımlilikleri yükleyin
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt

# 3. .env dosyasına Google API anahtarınızı ekleyin
echo GOOGLE_API_KEY=your_gemini_api_key_here > .env

# 4. Streamlit arayüzünü başlatın (veya baslat.bat dosyasını çalıştırın)
streamlit run app/streamlit_app.py
```